

# Spiegazione Homework #1 – MongoDB

Tutte le spiegazioni e i commenti sono presenti nel file **amazon-food-review.ipynb**

---

## Richiesta 3

### Complessità computazionale

Suddividere i dati in più collezioni (score1, score2, score3, score4, score5) aumenta la complessità delle query analitiche dal punto di vista implementativo.

Molte operazioni richiedono infatti di combinare dati provenienti da più collezioni, rendendo necessario eseguire più query o aggregazioni separate e poi unirne i risultati lato applicazione.

L'analisi di più collezioni implica comunque la scansione dei documenti presenti nel database; di conseguenza la complessità computazionale rimane approssimativamente  $O(n)$ , poiché è necessario leggere tutti i documenti per calcolare metriche aggregate come medie o conteggi.

Utilizzando invece una singola collezione reviews, le stesse operazioni potrebbero essere eseguite tramite una singola pipeline di aggregazione, mantenendo la stessa complessità teorica  $O(n)$  ma risultando più efficiente in pratica grazie all'ottimizzazione interna di MongoDB e alla possibilità di sfruttare indici sui campi score, product\_id e sentiment.

### Prestazioni delle operazioni di lettura e sulle risorse utilizzate

La suddivisione dei dati in più collezioni può migliorare le prestazioni in alcuni scenari specifici, in particolare quando le query devono analizzare solo un determinato livello di punteggio.

In questo caso il database deve accedere a una collezione più piccola, riducendo il numero di documenti da leggere e quindi il tempo di risposta (accesso puntuale).

Tuttavia, per molte interrogazioni analitiche che richiedono una visione globale dei dati (ad esempio il calcolo della media dei punteggi per prodotto o l'analisi del sentiment complessivo), è necessario interrogare tutte le collezioni e combinare i risultati.

Questo comporta un maggiore carico di lettura e un utilizzo più elevato delle risorse, poiché il sistema deve eseguire più operazioni di accesso ai dati.

Utilizzando invece una singola collezione reviews, le operazioni di lettura possono essere ottimizzate tramite indici sui campi score, product\_id e sentiment. In questo modo il motore DB può eseguire le aggregazioni in modo più efficiente all'interno di una singola pipeline, riducendo il numero di query e il trasferimento di dati tra database e applicazione.

## Manutenibilità e scalabilità

Dal punto di vista della manutenibilità, avere più collezioni separate può rendere il database più difficile da gestire. Ogni modifica alla struttura dei documenti, agli indici o alle query deve essere applicata a tutte le collezioni, aumentando il lavoro di manutenzione e la possibilità di errori o incoerenze.

Utilizzando invece una sola collezione reviews, la gestione del database risulta più semplice, perché tutti i dati sono concentrati nello stesso posto. Questo rende più facile modificare lo schema dei documenti, aggiungere nuovi indici o sviluppare nuove query.

Per quanto riguarda la scalabilità, la suddivisione in più collezioni può essere utile perché rappresenta una forma di partizionamento logico dei dati. In alcuni casi, questo può facilitare la distribuzione del carico di lavoro o l'analisi separata di sottoinsiemi del dataset.

Tuttavia, MongoDB permette di scalare anche utilizzando una singola collezione ben indicizzata, sfruttando funzionalità come replica e sharding nonché tecnica di partizionamento orizzontale dei database che suddivide grandi dataset in porzioni più piccole e gestibili ([Pure Storage](#)). Per questo motivo, in molti casi una singola collezione risulta più semplice da gestire e sufficientemente scalabile per dataset di grandi dimensioni.

### Richiesta 4

#### Co-occorrenza utenti:

- Se gli utenti che hanno recensito positivamente P12345 hanno recensito anche P999, allora P999 è un buon candidato.
- Più utenti in comune ci sono, più alto è il punteggio.

#### Media sentiment positivo:

- Tra i candidati, preferisci prodotti che hanno recensioni mediamente più positive.
  - Quindi un prodotto con molti positive è favorito.

#### Similarità lessicale:

- Confronti il testo delle recensioni del prodotto target con quello dei candidati.
- Se le recensioni parlano di cose simili, il prodotto viene considerato più vicino al target.

**Sistema di raccomandazione: ibrido**

- Collaborative filtering
- Content-based filtering
- Un elemento di Quality scoring (media dei sentiment)

## Richiesta 5

### Possibili cause

Le variazioni del sentiment nel tempo possono essere dovute a diversi fattori:

- cambiamenti nella qualità del prodotto
- modifiche nella composizione o nella produzione dell'azienda dovuto ad un possibile cambio della linea produttiva
- problemi nella distribuzione
- aspettative degli utenti o cambiamenti nel mercato
- cambiamento nei fornitori di materie prime o semi-lavorati
- cambiamento dovuto ad adattamenti a vari standard (AI-ACT), gestione privacy ecc

Un aumento improvviso del sentiment negativo potrebbe indicare un peggioramento percepito nella qualità del prodotto.

### Adattamento del sistema di raccomandazione

Un sistema di raccomandazione potrebbe adattarsi a questi cambiamenti considerando la tendenza temporale del sentiment.

Ad esempio, se un prodotto mostra un aumento significativo delle recensioni negative negli ultimi mesi, il sistema potrebbe ridurre il peso di tale prodotto nelle raccomandazioni oppure favorire prodotti alternativi con una tendenza più positiva, così da evitare un danno di immagine dell'azienda data da un singolo prodotto fallimentare o in declino.